

7.1. População, Amostra e Inferência Estatística

O objectivo fundamental da estatística é inferir as características de uma população, a partir de resultados observados numa ou mais amostras extraídas dessa população.

► *O processo de obtenção/extracção de amostras é designado de amostragem.*

Exemplo

Tirar conclusões sobre as alturas (ou pesos) dos estudantes do IPB (*população*) observando apenas um grupo de 100 estudantes (*amostra*) seleccionados na população.

7.2. Amostragem Aleatória

Para se poderem tirar **conclusões representativas** acerca de uma população a partir da análise de uma amostra, a **recolha da amostra a utilizar deve ser feita de acordo com certas regras**.

Considere-se uma população constituída por M elementos (ex. alunos do IPB) e a variável aleatória X que representa uma característica da população a estudar (ex. altura).

- Para obter uma amostra de tamanho n ($n < M$) deve escolher-se aleatoriamente um indivíduo da população. Dessa forma, esse indivíduo (altura) pode tomar qualquer valor entre todas as alturas possíveis.

x_1 – altura do 1º indivíduo seleccionado → valor da variável aleatória X_1

x_2 – altura do 2º indivíduo seleccionado → valor da variável aleatória X_2

x_3 – altura do 3º indivíduo seleccionado → valor da variável aleatória X_3

\vdots

x_n – altura do n indivíduo seleccionado → valor da variável aleatória X_n

- ▶ **O processo de amostragem diz-se aleatório** (e as amostras aleatórias) **quando as funções de probabilidade de X_1, X_2, \dots, X_n são idênticas à função $p(x)$:**

$$\forall_X : p(x_1) = p(x_2) = \dots = p(x_n) = p(x)$$

- ▶ A justificação básica para se utilizar a **amostragem aleatória** é assegurar que as **inferências** feitas a partir dos dados amostrais **não são distorcidas por um enviesamento na selecção**. Tal enviesamento existirá sempre que ocorrer uma tendência sistemática para **sobrerrepresentar ou subrepresentar** uma parte da população.

Como obter uma amostra aleatória de dimensão n ?

- (1) Numerar de 1 até M todos os elementos da população;
- (2) Colocar bolas numeradas de 1 até M numa urna;
- (3) Retirar uma bola, seleccionar o elemento da população com o número correspondente e registar a sua altura;
- (4) Repor a bola na urna;
- (5) Repetir os passos (3) e (4) até terem sido registadas as alturas de n elementos.

► Quando a *amostragem é feita com reposição* as variáveis X_1, X_2, \dots, X_n são independentes.

► Um processo de amostragem aleatória com estas características diz-se *aleatório simples*, verificando-se:

$$p_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) = p(x_1) \times p(x_2) \times \dots \times p(x_n)$$

► Quando $M \rightarrow \infty$ (e a dimensão da amostra, n , se mantém finita), a dependência entre as variáveis X_1, X_2, \dots, X_n tende a desaparecer. **Quando a população é infinita, é indiferente realizar a amostragem aleatória com ou sem reposição** (a amostragem é aleatória simples em qualquer dos casos).

7.3. Distribuições Amostrais

parâmetros populacionais \neq estatísticas amostrais



Para uma dada população e uma variável aleatória sobre ela definida, ***os parâmetros da distribuição correspondente são fixos enquanto que as medidas estatísticas variam de amostra para amostra.***

- ▶ Uma ***estatística amostral*** calculada a partir de X_1, X_2, \dots, X_n é uma função de várias variáveis aleatórias e é, portanto, ***ela própria uma variável aleatória.*** A ***distribuição de probabilidade de uma estatística amostral designa-se distribuição amostral da estatística.***

- ▶ Naturalmente, podemos calcular, para uma distribuição amostral, a média, a variância, desvio padrão, etc.
- ▶ ***O conceito de distribuição amostral de estatísticas será abordado considerando apenas o caso de estas serem obtidas com base em amostragens aleatórias.***

7.3.1. Distribuição da Média Amostral

Valor esperado	$E(\bar{X}) = \mu_{\bar{X}} = \mu_X$
Variância	$VAR(\bar{X}) = \sigma_{\bar{X}}^2 = \frac{\sigma_X^2}{n}$ <i>(população infinita ou finita com reposição)</i>
	$VAR(\bar{X}) = \sigma_{\bar{X}}^2 = \frac{\sigma_X^2}{n} \times \left(\frac{M-n}{M-1}\right)$ <i>(população finita, sem reposição)</i>

Justificação:

$$\begin{aligned}
 E(\bar{X}) &= E\left(\frac{1}{n} \times \sum_{i=1}^n X_i\right) = \frac{1}{n} \times E\left(\sum_{i=1}^n X_i\right) = \frac{1}{n} \times E(X_1 + X_2 + \dots + X_n) = \\
 &= \frac{1}{n} \times [E(X_1) + E(X_2) + \dots + E(X_n)] = \frac{1}{n} \times \sum_{i=1}^n E(X) = \frac{1}{n} \times [n \times E(X)] = E(X)
 \end{aligned}$$

$$\begin{aligned}
 Var(\bar{X}) &= Var\left(\frac{1}{n} \times \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \times Var\left(\sum_{i=1}^n X_i\right) = \frac{1}{n^2} \times Var(X_1 + X_2 + \dots + X_n) = \\
 &= \frac{1}{n^2} \times [Var(X_1) + Var(X_2) + \dots + Var(X_n)] = \\
 &= \frac{1}{n^2} \times \sum_{i=1}^n Var(X) = \frac{1}{n^2} \times [n \times Var(X)] = \frac{Var(X)}{n} \quad \text{(população infinita ou finita com reposição)}
 \end{aligned}$$

Exemplo

Considere-se uma população com quatro elementos aos quais se associam os seguintes valores da variável aleatória X : $\{2, 4, 6, 6\}$

- (a) Qual a função de probabilidade $p(x)$?
- (b) Defina a função de probabilidade de \bar{X} e a média amostral, calculadas para amostras aleatórias de dimensão 2 (amostras sem reposição).

Forma da Distribuição da Média Amostral quando a População é Normal

Quando a população é normal, a distribuição da média amostral também é normal.

- (1) A média amostral é uma combinação linear das variáveis X_i .
- (2) Se a população for normal, então

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

é uma combinação linear de variáveis normais.

- (3) Qualquer combinação linear de variáveis normais é, ela própria, uma variável normal.

- ▶ Sendo a *população normal*, presume, em rigor, que a *população é infinita*. Nesta situação:

$$\bar{X} \rightarrow N \left(\mu_X, \frac{\sigma_X^2}{n} \right) \quad \text{população infinita}$$

- ▶ Se se admitir que a *população é finita mas de grande dimensão*, com uma *distribuição aproximadamente normal*, e que a *amostra é também de grande dimensão*, então na definição de \bar{X} deve-se entrar em *consideração com o factor de redução*, vindo:

$$\bar{X} \rightarrow N \left(\mu_X, \frac{\sigma_X^2}{n} \times \frac{M - n}{M - 1} \right) \quad \text{população finita e amostra de grande dimensão}$$

7.4. Teorema do Limite Central

- (1) Sejam X_1, X_2, \dots, X_n ***variáveis independentes com distribuições idênticas*** (com valor esperado μ_X e variância σ_X^2 finitos).

- Qualquer que seja a forma da distribuição comum aos X_i 's, a distribuição da variável soma

$$S = \sum_{i=1}^n X_i$$

tende para uma distribuição normal à medida que n aumenta.

- Qualquer que seja a distribuição de uma população (com valor esperado μ_X e variância σ_X^2 finitos), então a distribuição da média amostral

$$\bar{X} = \frac{1}{n} \times S$$

tende para uma distribuição normal quando a dimensão da amostra, n , tende para infinito.

(presupõe-se que a amostragem é aleatória simples, para que as variáveis X_i sejam independentes)

(2) As condições apresentadas em (1) podem ser relaxadas de duas formas:

- ▶ As variáveis X_1, X_2, \dots, X_n **podem ter distribuições diferentes** umas das outras (desde que se verifique a condição de que **a contribuição da variância de cada uma delas para a variância da soma seja relativamente pequena**).
- ▶ As variáveis X_1, X_2, \dots, X_n **podem ser dependentes desde que a correlação seja fraca**.


Questão: Quando é que o valor de n é suficientemente grande para que a distribuição Normal seja efectivamente uma boa aproximação da média amostral?

R: Para um dado valor de n , **o rigor da aproximação depende da forma da distribuição original sendo, em particular, tanto menor quanto maior for a assimetria desta**.

Regra Prática: $n \geq 10$ se a distribuição original for simétrica
 $n \geq 50$ se a distribuição original for muito assimétrica

Teorema do Limite Central

Para uma qualquer população (caracterizada por uma qualquer distribuição) com variância finita, a distribuição da média amostral calculada com base numa amostra aleatória simples tende para uma distribuição normal, à medida que a dimensão da amostra aumenta.



Exemplo

O custo de transporte de um lote de determinada matéria-prima depende da localização do fornecedor. Sabe-se que o custo é caracterizado por uma distribuição normal com valor médio igual a 575 u.m. e desvio padrão igual a 100 u.m..

- a) Se forem adquiridos 10 lotes da referida matéria-prima a diferentes fornecedores, qual a média e a variância do custo médio desses lotes?
Qual a probabilidade desse custo ultrapassar 6000 u.m.?
- b) Determine a probabilidade do custo médio dos 10 lotes adquiridos ser superior a 600 u.m..