

## 4.1. Definição de Distribuição Conjunta

Para um **mesmo espaço amostral ( $S$ )** podem definir-se **várias variáveis aleatórias**. As diferentes variáveis aleatórias possuem **características próprias que as individualizam** mas **podem também apresentar características de natureza conjunta que merecem ser identificadas**.

## 4.2. Função de Probabilidade Conjunta de Duas Variáveis Discretas

$$p(x, y) = \text{PROB}(X = x \wedge Y = y)$$

$$\blacktriangleright \sum_X \sum_Y p(x, y) = 1$$

### 4.3. Função de Probabilidade Conjunta de Duas Variáveis Contínuas

$$f(x, y) = \text{PROB} \{X \in [x, x + dx], Y \in [y, y + dy]\}$$

A probabilidade de um par de valores  $(X, Y)$  se situar no domínio  $D$  é dada por:

$$\text{PROB} \{(X, Y) \in D\} = \int \int_D f(x, y) dx dy$$

►  $\int \int_S f(x, y) dx dy = 1$

## 4.4. Distribuições Marginais

Quando as distribuições  $p_X(x)$  e  $p_Y(y)$  são obtidas a partir de  $p(x,y)$ , designam-se por *distribuições marginais*.

### 4.4.1. Função de Probabilidade Marginal de Duas Variáveis Discretas

$$p_X(x) = \sum_Y p(x,y)$$

$$p_Y(y) = \sum_X p(x,y)$$

### 4.4.2. Função de Probabilidade Marginal de Duas Variáveis Contínuas

$$f_X(x) = \int_Y f(x,y) dy$$

$$f_Y(y) = \int_X f(x,y) dx$$

## Exemplo

Considere duas variáveis aleatórias  $X$  e  $Y$  cuja função de probabilidade conjunta  $p(x,y)$  se apresenta no quadro seguinte:

DGI

2019

	$Y$	1	2	3
$X$				
2		$2k$	0.18	0.18
3		0.16	0.12	$k$

1. Determine o valor de  $k$ ?

$$\sum_x \sum_y p(x,y) = 1 \Leftrightarrow k = 0.12$$

		$Y$			$p_X(x)$
		1	2	3	
$X$	2	0.24	0.18	0.18	0.60
	3	0.16	0.12	0.12	0.40
$p_Y(y)$		0.40	0.30	0.30	<b>1.00</b>

**Exemplo** (cont.)

2. Deduza a função de probabilidade de  $Y$ .

DGI

2019

$$p_Y(y) = \sum_X p(x, y)$$

$y$	$p(y)$
1	0.4
2	0.3
3	0.3
$\sum$	1

## 4.5. Distribuições Condicionais

### 4.5.1. Função de Probabilidade Condicional de duas Variáveis Discretas

$$p_{X|Y}(x|y) = \frac{p(x,y)}{P_Y(y)}$$

$$p_{Y|X}(y|x) = \frac{p(x,y)}{P_X(x)}$$

### 4.5.2. Função de Probabilidade Condicional de duas Variáveis Contínuas

$$f_{X|Y}(x|y) = \frac{f(x,y)}{\int_X f(x,y) dx}$$

$$f_{Y|X}(y|x) = \frac{f(x,y)}{\int_Y f(x,y) dy}$$

## 4.6. Independência

Sejam  $X$  e  $Y$  duas variáveis aleatórias discretas. Tais variáveis dizem-se **independentes se e só se, para todos os valores de  $X$  e de  $Y$ , os acontecimentos:**

$$X = x \quad \text{e} \quad Y = y \quad \text{forem independentes}$$

Tal implica que:

$$PROB(X = x|Y = y) = PROB(X = x), \forall_{x,y}$$

$$PROB(Y = y|X = x) = PROB(Y = y), \forall_{x,y}$$

donde

$$p_{X|Y}(x|y) = \frac{p(x,y)}{P_Y(y)} = p_X(x), \quad \forall_{x,y}$$

$$p_{Y|X}(y|x) = \frac{p(x,y)}{P_X(x)} = p_Y(y), \quad \forall_{x,y}$$

ou

$$p(x,y) = p_X(x) \times p_Y(y), \quad \forall_{x,y}$$

O conceito de independência pode estender-se ao caso de variáveis contínuas. Se  $X$  e  $Y$  forem *duas variáveis contínuas*, elas são *independentes* se e só se:

$$\forall_{x,y} : f(x,y) = f_X(x) \times f_Y(y)$$

**Exemplo** (cont.)

**3.** Verifique se as variáveis são independentes.

DGI

2019

As variáveis são independentes se:

$$\forall_{x,y} p(x,y) = p(x) \times p(y)$$

		Y			$p_X(x)$
		1	2	3	
X	2	0.24	0.18	0.18	0.6
	3	0.16	0.12	0.12	0.4
$p_Y(y)$		0.4	0.3	0.3	<b>1</b>

$$\begin{array}{c}
 0.24 = 0.6 \times 0.4 \quad \checkmark \quad | \quad 0.18 = 0.6 \times 0.3 \quad \checkmark \quad | \quad 0.18 = 0.6 \times 0.3 \quad \checkmark \\
 \hline
 0.16 = 0.4 \times 0.4 \quad \checkmark \quad | \quad 0.12 = 0.4 \times 0.3 \quad \checkmark \quad | \quad 0.12 = 0.4 \times 0.3 \quad \checkmark
 \end{array}$$

→ são independentes

## 4.7. Covariância e Correlação

**Se duas variáveis são independentes então, entre elas, não existe qualquer relação.**

É de esperar que as seguintes variáveis sejam independentes:

- ▶ *Cor dos olhos dos professores do IPB*
- ▶ *Disciplinas que leccionam*
- ▶ No que diz respeito às variáveis altura e peso dos professores, é de esperar que elas não sejam independentes. Embora possa haver excepções, é de esperar que o peso tenda a aumentar com o aumento da altura.

Existem **várias possibilidades de relacionamento** entre o peso e a altura que satisfaçam a condição enunciada (relação linear, quadrática, exponencial, etc.). De todas elas a *mais simples é a linear, que pode ser utilizada como aproximação das restantes. A Covariância e a Correlação são medidas do grau de relacionamento linear entre duas variáveis.*

#### 4.7.1. Covariância

$$\sigma_{xy} = \sum_X \sum_Y (x - \mu_X)(y - \mu_Y) \times p(x, y) \quad (\text{variáveis discretas})$$

$$\sigma_{xy} = \int \int (x - \mu_X)(y - \mu_Y) \times f(x, y) dx dy \quad (\text{variáveis contínuas})$$

De uma forma geral, tanto para as variáveis discretas ou contínuas

verifica-se que:  $\sigma_{xy} = E[(x - \mu_X)(y - \mu_Y)]$

#### 4.7.2. Correlação

$$\rho_{xy} = \frac{\sigma_{xy}}{\sigma_x \cdot \sigma_y} = \frac{E[(x - \mu_X)(y - \mu_Y)]}{\sqrt{E[(x - \mu_X)^2] \times E[(y - \mu_Y)^2]}}$$

A correlação pode ser interpretada como a covariância das variáveis padronizadas:

$$X^* = \frac{x - \mu_X}{\sigma_X} \quad \text{e} \quad Y^* = \frac{y - \mu_Y}{\sigma_Y}$$

É de esperar que as seguintes variáveis sejam independentes:

- O coeficiente de correlação  $\rho_{XY}$  toma valores compreendidos entre -1 e 1

$$-1 \leq \rho_{xy} \leq 1$$

$\rho_{xy}$	Interpretação
1	Relacionamento linear perfeito ( <i>directo</i> )
0	Ausência de relação linear
-1	Relacionamento linear perfeito ( <i>inverso</i> )

*Se  $\rho_{XY} = 0$  não se pode concluir que  $X$  e  $Y$  sejam independentes.  $\rho_{XY} = 0$  significa apenas que não existe uma relação linear entre  $X$  e  $Y$ . Poderão existir relações não lineares entre elas.*

**Covariância positiva:** quando uma das variáveis se desvia significativamente do seu valor esperado a outra também tenderá a desviar-se no mesmo sentido. Tal acarretará um *aumento da dispersão da soma das duas variáveis*.

**Covariância negativa:** Os desvios das duas variáveis serão mais frequentemente de sentido contrário, implicando uma *diminuição da dispersão da sua soma*.

#### 4.8. Valor Esperado e Variância de uma Função de várias Variáveis Aleatórias

Considerem-se duas variáveis aleatórias quaisquer, discretas ou contínuas ( $X$  e  $Y$ )  
e defina-se uma nova variável aleatória  $Z$  como função das anteriores

$$Z = g(X, Y)$$

Considere o caso:  $Z = g(X, Y) = X + Y$

Neste caso, o *valor esperado e a variância de  $Z$*  vêm dados por:

$$\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y) = \mu_X + \mu_Y$$

$$\text{VAR}(X + Y) = \text{VAR}(X) + 2 \times \text{COV}(X, Y) + \text{VAR}(Y) = \sigma^2_X + 2 \times \sigma_{XY} + \sigma^2_Y$$

**Exemplo** (cont.)

4. Considere uma nova variável  $Z = X - Y$ . Calcule a sua variância e o seu valor esperado

$$Z = X - Y$$

$$E(Z) = E(X) - E(Y) = \mu_X - \mu_Y = 0.5$$

$$VAR(Z) = VAR(X - Y) = VAR(X) + 2 \times COV(X, Y) + VAR(Y) =$$

X, Y independentes  $\rightarrow$   $= VAR(X) + VAR(Y) =$   
 $= 0.24 + 0.69 = 0.93$

Quando  $X$  e  $Y$  forem não correlacionadas (*independentes*):

$$\text{VAR}(X + Y) = \text{VAR}(X) + \text{VAR}(Y) = \sigma^2_X + \sigma^2_Y$$

Quando  $X$  e  $Y$  forem *perfeitamente correlacionadas*:

$$\frac{\sigma_{XY}}{\sigma_X \times \sigma_Y} = 1 \quad \Rightarrow \quad \sigma_{XY} = \sigma_X \times \sigma_Y$$

Considere-se agora o caso em que a variável  $Z = g(X, Y)$  é uma *combinação linear de X e Y*:

$$Z = g(X, Y) = a \times X + b \times Y$$

Neste caso, o *valor esperado* e a *variância* de  $Z$  vêm dados por:

$$\text{E}(a \times X + b \times Y) = a \times \text{E}(X) + b \times \text{E}(Y) = a \times \mu_X + b \times \mu_Y$$

$$\begin{aligned}\text{VAR}(a \times X + b \times Y) &= a^2 \times \text{VAR}(X) + 2 \times a \times b \times \text{COV}(X, Y) + b^2 \times \text{VAR}(Y) = \\ &= a^2 \times \sigma_X^2 + 2 \times a \times b \times \sigma_{XY} + b^2 \times \sigma_Y^2\end{aligned}$$

Considere-se finalmente o caso em que  $Z$  é uma função não linear em  $X$  e/ou em  $Y$ . Neste caso é possível obter *aproximações de  $E(Z)$  e  $Var(Z)$  a partir de uma aproximação linear de  $g(X, Y)$  em torno de  $(\mu_X, \mu_Y)$* :

$$g(X, Y) \approx g(\mu_X, \mu_Y) + (X - \mu_X) \cdot \frac{\partial g}{\partial X} \Big|_{\substack{X=\mu_X \\ Y=\mu_Y}} + (Y - \mu_Y) \cdot \frac{\partial g}{\partial Y} \Big|_{\substack{X=\mu_X \\ Y=\mu_Y}}$$

Neste caso o *valor esperado* e a *variância* de  $Z$  vêm dados por:

$$E[g(X, Y)] \approx g[E(X), E(Y)] = g(\mu_X, \mu_Y)$$

$$\begin{aligned} \text{VAR}[g(X, Y)] &\approx \left( \frac{\partial g}{\partial X} \Big|_{\substack{X=\mu_X \\ Y=\mu_Y}} \right)^2 \times \sigma^2_X + \\ &+ 2 \times \left( \frac{\partial g}{\partial X} \Big|_{\substack{X=\mu_X \\ Y=\mu_Y}} \right) \left( \frac{\partial g}{\partial Y} \Big|_{\substack{X=\mu_X \\ Y=\mu_Y}} + \right) \times \sigma_{XY} + \left( \frac{\partial g}{\partial Y} \Big|_{\substack{X=\mu_X \\ Y=\mu_Y}} \right)^2 \times \sigma^2_Y \end{aligned}$$