

8.1. Estimadores

No âmbito da inferência estatística, ao calcular uma estatística (por exemplo uma média amostral) o objectivo passa a ser o de **caracterizar** um conjunto mais vasto de dados: a **população a partir da qual a amostra foi retirada**.

- ▶ A **forma mais directa** de se proceder a uma inferência estatística corresponde à **estimação pontual de parâmetros**.
- ▶ **Designa-se por estimador (pontual) de um parâmetro uma estatística cujo valor constitui uma estimativa do parâmetro em causa.**

Exemplos

A média amostral (\bar{X}) é um estimador do valor esperado (μ_X) da população


O erro quadrático médio (EQM_X) é um estimador da variância (σ_X^2) da população

8.2. Propriedades Desejáveis dos Estimadores


8.2.1. Enviesamento

Seja θ um parâmetro qualquer de uma população e $\hat{\theta}$ um estimador desse parâmetro.

- ▶ O estimador diz-se não **enviesado** quando o seu valor esperado coincidir com o valor do parâmetro.



$$E[\hat{\theta}] = \theta$$




$$\text{Enviesamento} = E[\hat{\theta}] - \theta$$

- ▶ O estimador será enviesado se a diferença $E(\hat{\theta}) - \theta$ for maior ou menor do que zero. Tal diferença designa-se por enviesamento.

8.2.2. Eficiência

Considere-se o caso de dois estimadores não enviesados $(\hat{\theta}_1, \hat{\theta}_2)$ de um mesmo parâmetro θ . Admita-se que, para amostras de dimensão n , as variâncias daqueles estimadores são σ^2_1 e σ^2_2 , com $\sigma^2_1 < \sigma^2_2$.



- Neste caso, o estimador $\hat{\theta}_1$ é melhor, a sua distribuição é mais concentrada em torno de θ ou seja tem uma menor variância – $\hat{\theta}_1$ é pois um estimador mais eficiente.

$$\text{Eficiência relativa entre } \hat{\theta}_1 \text{ e } \hat{\theta}_2 = \frac{VAR(\hat{\theta}_1)}{VAR(\hat{\theta}_2)}$$

- Quando **dois estimadores são não enviesados, o melhor estimador é aquele que tem menor variância.**

Exemplo

Com base numa amostra de duas observações, considere os dois estimadores seguintes para a média:

$$U = \frac{1}{2}X_1 + \frac{1}{2}X_2$$

$$V = \frac{1}{3}X_1 + \frac{2}{3}X_2$$

- (a) U e V são estimadores enviesados?
- (b) Qual o estimador mais eficiente?

Generalize-se agora a comparação entre estimadores, admitindo que estes podem ser enviesados.


A medida da eficiência do estimador $\hat{\theta}$ será o desvio quadrático médio (DQM), dado por:

$$DQM = E \left[(\hat{\theta} - \theta)^2 \right] = \sigma_{\hat{\theta}}^2 + (\text{enviesamento})^2$$

► Para quaisquer dois estimadores, enviesados ou não enviesados:

$$\text{Eficiencia relativa de } \theta_1 \text{ e } \theta_2 = \frac{DQM(\theta_1)}{DQM(\theta_2)}$$

Considere-se o exemplo da figura. Dos três estimadores $(\hat{\theta}_1, \hat{\theta}_2, \hat{\theta}_3)$, o de menor variância $\hat{\theta}_3$ está longe de ser o melhor, dado que é muito mais enviesado do que os outros dois. O melhor também não será o que apresenta enviesamento nulo ($\hat{\theta}_1$), dado que tem uma variância muito grande. Restará possivelmente $\hat{\theta}_2$ como o melhor compromisso.



- Se existir um estimador que seja mais eficiente do que qualquer outro então diz-se que o estimador é eficiente (ou absolutamente eficiente).


8.2.3. Consistência

Seja $\hat{\theta}$ um estimador do parâmetro θ e n a dimensão da amostra com base na qual $\hat{\theta}$ é calculado.

- O estimador $\hat{\theta}$ diz-se consistente quando, para qualquer valor positivo δ , se verifica que:

$$\lim_{n \rightarrow \infty} \text{PROB} \left(|\hat{\theta} - \theta| < \delta \right) = 1$$

Isto é, quando $n \rightarrow \infty$ o estimador consistente concentra-se perfeitamente sobre o seu alvo (o valor do parâmetro estimado).



8.3. Métodos de Estimação

8.3.1. Método da Máxima Verosimilhança

Considere-se uma população com função densidade que contenha um parâmetro populacional, θ , a ser estimado por meio de determinada estatística. A função densidade pode neste caso ser denotada por $f(x, \theta)$. Admitindo que haja n observações independentes, X_1, X_2, \dots, X_n , a função densidade conjunta para essas observações é:

$$L = f(x_1, \theta) f(x_2, \theta) \dots f(x_n, \theta) ; \quad (L \equiv \text{verosimilhança})$$

A máxima verosimilhança é obtida, derivando L em ordem a θ e igualando a zero:

$$\frac{dL}{d\theta} = 0$$

- Para o caso de vários parâmetros (k parâmetros), deverão ser tomadas as várias derivadas parciais em relação a cada um deles:

$$L = f(x_1, \theta_1) f(x_2, \theta_2) \dots f(x_n, \theta_k) \quad \frac{\partial L}{\partial \theta_i} = 0 \quad ; \quad (i = 1, 2, \dots, k)$$

Na generalidade dos casos, os estimadores de máxima verosimilhança são dos melhores que se podem obter, apresentando as seguintes características:

- (1) Em geral são consistentes;
- (2) Embora nem sempre sejam não enviesados e eficientes para amostras pequenas, tendem a possuir aquelas propriedades à medida que a dimensão da amostra cresce;
- (3) As suas distribuições aproximam-se de distribuições normais quando a dimensão da amostra tende para infinito.

8.3.2. Método da Estimação Linear com Variância mínima

Para que o **método da máxima verosimilhança possa ser aplicado, há que especificar previamente o tipo de distribuição da população. No método da estimação linear com variância mínima tal especificação não é necessária.**

- ▶ O método consiste em **combinar linearmente um conjunto de estimadores não-enviesados com variância mínima.**

No caso geral de uma *combinação linear de k estimadores*, obtem-se:

$$\hat{\theta} = \sum_{i=1}^k a_i \times \hat{\theta}_i \quad \text{com} \quad a_i = \frac{1/\sigma_i^2}{\sum_{j=1}^k (1/\sigma_j^2)}$$